

SPRAWOZDANIE - LABORATORIUM 5

Diagonalizacja macierzy metodą potęgową.

Katarzyna Such, 09.04.2021

1 Wstęp teoretyczny

W trakcie laboratorium rozwiązywaliśmy problem własny macierzy przy pomocy metody iteracyjnej.

$$\mathbf{A}\vec{x} = \lambda\vec{x}, \quad \{\lambda_1, \lambda_2, \dots, \lambda_n\}, \{x_1, x_2, \dots, x_n\} \quad (1)$$

Przy założeniu, że macierz \mathbf{A} jest macierzą symetryczną stosowaliśmy metodę potęgową. Jest to metoda wielokrotnych przybliżeń, która pozwala wyznaczyć największą wartość własną i odpowiadający jej wektor własny. Żeby rozwiązać powyższy problem, należy, pewną liczbę razy, wykonać kolejne kroki:

- wybranie dowolnego wektora: $\vec{v}_0 = \sum_{i=1}^n a_i \vec{x}_i$
- pomnożeniu wybranego wektora przez macierz \mathbf{A} :
 - $\mathbf{A}\vec{v}_0 = \sum_{i=1}^n a_i \lambda_i \vec{x}_i$
 - $\vec{v}_m = \mathbf{A}^m \vec{v}_0 = \sum_{i=1}^n a_i \lambda_i^m \vec{x}_i$
- wyznaczenie wektora (np. x_1):
 - ponieważ $\vec{v}_m \approx a_1 \lambda_1^m \vec{x}_1$
 - $\vec{x}_1 = \frac{\vec{v}_m}{\|\vec{v}_m\|}$ - znormalizowany wektor własny.

Kolejne przybliżenia wektora \vec{x} :

$$\vec{x}_0^{i+1} = \frac{\mathbf{A} \vec{x}_0^i}{\|\mathbf{A} \vec{x}_0^i\|} \quad (2)$$

Dzięki redukcji Hotellinga, możemy wyznaczyć kolejne wektory własne (i-te przybliżenie k-tej wartości własnej):

$$\mathbf{W}_{k+1} = \mathbf{W}_k - \lambda_k \vec{x}_k^i (\vec{x}_k^i)^T \quad (3)$$

gdzie:

$$\lambda_k = \frac{(\vec{x}_k^{i+1})^T \vec{x}_k^i}{(\vec{x}_k^i)^T \vec{x}_k^i} \quad (4)$$

2 Zadanie do wykonania

2.1 Opis problemu

Utorzyliśmy symetryczną macierz \mathbf{A} ($n = 7$) gdzie:

$$A_{ij} = \frac{1}{\sqrt{2 + |i - j|}} \quad (5)$$

Przy użyciu metody potęgowej wyznaczyliśmy wartości własne. Stosowaliśmy poniższy algorytm:

```

W0 = A           (inicjalizacja macierzy iterującej)
for (int k=0; k < Kval; k++) {
     $\vec{x}_k^0 = [1, 1, \dots, 1]$            (inicjalizacja wektora startowego)
    for( int i= 1; i <= IT_MAX; i++){
         $\vec{x}_k^{i+1} = \mathbf{W}_k \vec{x}_k^i$ 
         $\lambda_k^i = \frac{(\vec{x}_k^{i+1})^T \vec{x}_k^i}{(\vec{x}_k^i)^T \vec{x}_k^i}$ 
         $\vec{x}_k^i = \frac{\vec{x}_k^{i+1}}{\|\vec{x}_k^{i+1}\|_2}$ 
    }
    Wk+1 = Wk -  $\lambda_k \vec{x}_k^i (\vec{x}_k^i)^T$            (iloczyn tensorowy)
}

```

gdzie:

- k - numer wyznaczonej wartości własnej,
- i - numer iteracji dla określonego k,
- **A** - macierz pierwotna,
- **W**_k - macierz iteracji,
- λ_k^i - przybliżenie k-tej wartości własnej w i-tej iteracji,
- \vec{x}_k^i - i-te przybliżenie k-tego wektora własnego,
- K_{val} = n = 7 - ilość wartości własnych do wyznaczenia,
- IT_MAX = 12 - ilość iteracji

Wyznaczyliśmy macierz **X** = [$\vec{x}_0, \vec{x}_1, \dots, \vec{x}_{n-1}$], która przechowuje wektory własne.

Na podstawie macierzy **X**, znaleźliśmy macierz **D**:

$$\mathbf{D} = \mathbf{X}^T \mathbf{A} \mathbf{X} \quad (6)$$

2.2 Wyniki


Kolejne wektory własne:

$$\begin{aligned}
 \vec{x}_0 &= \begin{bmatrix} 0.352941 \\ 0.377935 \\ 0.392221 \\ 0.396889 \\ 0.392221 \\ 0.377935 \\ 0.352941 \end{bmatrix} &
 \vec{x}_1 &= \begin{bmatrix} 0.477239 \\ 0.164774 \\ -0.314852 \\ -0.540298 \\ -0.314852 \\ 0.164774 \\ 0.477239 \end{bmatrix} &
 \vec{x}_2 &= \begin{bmatrix} 0.361191 \\ -0.463966 \\ -0.14042 \\ 0.518765 \\ -0.14042 \\ -0.463967 \\ 0.36119 \end{bmatrix} &
 \vec{x}_3 &= \begin{bmatrix} -0.479159 \\ -0.446634 \\ -0.266307 \\ -3.98951 \cdot 10^{-5} \\ 0.266379 \\ 0.446583 \\ 0.479179 \end{bmatrix} \\
 \vec{x}_4 &= \begin{bmatrix} 0.130873 \\ -0.337792 \\ 0.477129 \\ -0.531332 \\ 0.476855 \\ -0.338251 \\ 0.130381 \end{bmatrix} &
 \vec{x}_5 &= \begin{bmatrix} -0.449005 \\ 0.172676 \\ 0.518245 \\ -5.19045 \cdot 10^{-10} \\ -0.518245 \\ -0.172676 \\ 0.449005 \end{bmatrix} &
 \vec{x}_6 &= \begin{bmatrix} 0.262282 \\ -0.520312 \\ 0.400604 \\ -9.77221 \cdot 10^{-14} \\ -0.400604 \\ 0.520312 \\ -0.262282 \end{bmatrix}
 \end{aligned}$$


Macierz $\mathbf{D} = \mathbf{X}^T \mathbf{A} \mathbf{X}$:

| | | | | | | |
|---------------------------|---------------------------|---------------------------|---------------------------|----------------------------|---------------------------|---------------------------|
| 3.59586 | $-1.18905 \cdot 10^{-13}$ | $2.16493 \cdot 10^{-15}$ | $2.22045 \cdot 10^{-16}$ | $-2.22045e \cdot 10^{-15}$ | $2.22045 \cdot 10^{-16}$ | $-2.22045 \cdot 10^{-16}$ |
| $-1.18898 \cdot 10^{-13}$ | 0.284988 | $-6.25267 \cdot 10^{-06}$ | $-2.28247 \cdot 10^{-12}$ | $-3.81662 \cdot 10^{-09}$ | $-1.38778 \cdot 10^{-17}$ | $6.93889 \cdot 10^{-17}$ |
| $2.25861 \cdot 10^{-15}$ | $-6.25267 \cdot 10^{-06}$ | 0.122786 | $-8.92259 \cdot 10^{-07}$ | -0.000329107 | $-3.06873 \cdot 10^{-13}$ | $-2.25514 \cdot 10^{-17}$ |
| $-2.77556 \cdot 10^{-17}$ | $-2.28247 \cdot 10^{-12}$ | $-8.92259 \cdot 10^{-07}$ | 0.59039 | -0.000296956 | $-3.70259 \cdot 10^{-14}$ | $1.38778 \cdot 10^{-17}$ |
| $-2.12417 \cdot 10^{-15}$ | $-3.81662 \cdot 10^{-09}$ | -0.000329107 | -0.000296956 | 0.0865959 | $-2.45141 \cdot 10^{-10}$ | $-4.52416 \cdot 10^{-15}$ |
| $1.66533 \cdot 10^{-16}$ | $-6.93889 \cdot 10^{-18}$ | $-3.06897 \cdot 10^{-13}$ | $-3.69496 \cdot 10^{-14}$ | $-2.45141 \cdot 10^{-10}$ | 0.170974 | $-3.62189 \cdot 10^{-08}$ |
| $-2.84495 \cdot 10^{-16}$ | $2.08167 \cdot 10^{-17}$ | $1.73472 \cdot 10^{-18}$ | $-9.19403 \cdot 10^{-17}$ | $-4.48426 \cdot 10^{-15}$ | $-3.62189 \cdot 10^{-08}$ | 0.0981544 |

Kolejne przybliżenia znalezionych wartości własnych λ_k , dla 12 iteracji (Rysunek 1, Rysunek 2):




Rysunek 1: Przybliżenie znalezionej wartości własnej λ_0 w zależności od numeru iteracji.




Rysunek 2: Przybliżenia znalezionych wartości własnych λ_i , ($i \in [1, 6]$) w zależności od numeru iteracji.

Dla $IT_MAX = 300$ przybliżenia znalezionej wartości własnej λ_k , dla 300 iteracji (Rysunek 3, Rysunek 4):



Rysunek 3: Przybliżenie znalezionej wartości własnych λ_0 w zależności od numeru iteracji.



Rysunek 4: Przybliżenia znalezionej wartości własnych λ_i , ($i \in [1, 6]$) w zależności od numeru iteracji.

3 Wnioski

Teoretycznie dla metody potęgowej wartości własne λ_k dla kolejnych iteracji powinny maleć. Dla 12 iteracji, które przyjęliśmy w tym zadaniu, to założenie nie jest spełnione. Po zwiększeniu liczby iteracji do 300 jesteśmy w stanie zauważyć tę zależność.

Obliczone przez nas wartości własne są wartościami przybliżonymi. Macierz $\mathbf{D} = \mathbf{X}^T \mathbf{A} \mathbf{X}$ nie jest macierzą diagonalną, poza diagonalą znajdują się wartości rzędu 10^{-6} - 10^{-18} .

Z wykresów możemy odczytać, że dla różnych wartości własnych, potrzebna była inna ilość iteracji, aby wyniki w kolejnych iteracjach się pokrywały, np. dla λ_0 osiągnięto taki stan po 3 iteracjach, z drugiej strony dla λ_5 po około 250.

Metoda potęgowa jest dość szybka i prosta w implementacji dla macierzy niewielkich oraz symetrycznych. Dla małej macierzy, którą rozważaliśmy, zwiększenie ilości iteracji z 12 na 300, nie zmienia istotnie czasu działania programu.